

TEXT MINING

Scraping Web sobre la Última Convocatoria de España para el Mundial de Fútbol

Gonzalo Rodríguez Lorente-Sorolla

Asignatura: Text Mining

Trabajo Final

1. Introducción

El proyecto tiene como finalidad la aplicación de técnicas de web scraping y text mining sobre un conjunto de datos extraídos directamente de la web, tomando como caso de estudio la última convocatoria de la selección española de fútbol para un campeonato internacional elegida por nosotros. Este tipo de proyectos resulta de especial interés en el contexto académico de la asignatura, ya que permite poner en práctica el ciclo completo del análisis de datos: desde la obtención y limpieza de la información hasta su análisis y visualización de esta manera abarcamos todo lo dado durante el curso.

Para la obtención de los datos se ha seleccionado la plataforma Transfermarkt como fuente principal de información. Esta web especializada en el mercado de fichajes futbolísticos ofrece datos detallados y actualizados sobre cada jugador convocado, incluyendo variables como la posición en el campo, la edad, el club de procedencia y el valor de mercado estimado. A partir de la tabla correspondiente a la convocatoria de la selección española, se extrae la información mediante técnicas de scraping que automatizan el proceso de recolección de datos estructurados desde páginas web.

El objetivo principal del proyecto consiste en construir un dataset limpio, estructurado y listo para el análisis, partiendo de datos web que en su estado original no se encuentran en un formato directamente utilizable. Este proceso de transformación constituye una de las tareas fundamentales en cualquier

proyecto de ciencia de datos, y su correcta ejecución es esencial para garantizar la calidad y fiabilidad de los resultados obtenidos.

2. Fuente de los Datos

La fuente de datos seleccionada para este proyecto es Transfermarkt ([transfermarkt.es](https://www.transfermarkt.es)), una plataforma web de referencia en el ámbito del fútbol europeo y mundial. Este portal ofrece información exhaustiva y actualizada sobre jugadores, clubes, estadísticas de mercado y convocatorias nacionales, convirtiéndose en una de las bases de datos más completas y consultadas por analistas, periodistas y aficionados al fútbol.

Esta página entre otros contenidos, presenta una tabla estructurada con los jugadores de la última convocatoria, incluyendo para cada uno de ellos las siguientes variables:

- Nombre del jugador
- Posición en el campo (Portero, Defensa, Centrocampista o Delantero)
- Edad
- Club de procedencia
- Valor de mercado estimado (expresado en millones de euros)

La elección de Transfermarkt como fuente de datos responde a varios criterios. En primer lugar, la información que ofrece está estructurada de forma tabular dentro del código HTML de la página, lo que facilita considerablemente su extracción mediante técnicas de scraping. En segundo lugar, los datos son de dominio público y se actualizan periódicamente, garantizando su vigencia y relevancia. Por último, la plataforma proporciona una variable especialmente relevante para el análisis como es el valor de mercado, que no se encuentra de forma sistemática en otras fuentes alternativas y permite establecer comparaciones cuantitativas entre jugadores.

3. Metodología: Proceso de Scraping y Preparación de Datos

3.1. Librerías utilizadas

Para llevar a cabo el proyecto se han utilizado diversas librerías de Python, cada una con una función específica dentro del flujo de trabajo. Requests se emplea

para realizar peticiones HTTP y acceder al contenido de la página web. BeautifulSoup, perteneciente al paquete bs4, permite analizar y navegar por la estructura HTML del documento descargado. Pandas se utiliza para organizar y manipular los datos en formato de tabla (DataFrame). Matplotlib y Seaborn se emplean conjuntamente para la generación de visualizaciones gráficas. NumPy proporciona soporte para operaciones numéricas. Finalmente, NetworkX permite construir y representar grafos de red para visualizar relaciones entre entidades.

3.2. Acceso a la página web

El primer paso del proceso consiste en realizar una solicitud HTTP a la URL de Transfermarkt correspondiente a la selección española. Para evitar que el servidor rechace la petición al detectar que procede de un script automatizado, se define una cabecera HTTP personalizada que simula el comportamiento de un navegador web convencional mediante el campo User-Agent. Una vez obtenida la respuesta del servidor, el contenido HTML de la página se procesa con BeautifulSoup, que lo convierte en una estructura de árbol navegable sobre la que es posible aplicar búsquedas y selecciones de elementos específicos.

3.3. Extracción de datos

La extracción de los datos se realiza localizando en el HTML el contenedor principal de la tabla de jugadores, identificado por la clase CSS 'responsivetable'. A partir de ese elemento, se accede al cuerpo de la tabla (etiqueta tbody) y se itera sobre cada una de sus filas (etiquetas tr).

Para cada jugador, se extraen los valores correspondientes a cada columna de la tabla. La posición en el campo se obtiene del atributo 'title' de la primera celda. El nombre del jugador se extrae del enlace contenido dentro de la celda con clase 'hauptlink'. La edad, el club de procedencia y el valor de mercado se obtienen respectivamente de la segunda, tercera y cuarta celda restante. Aquellas filas que no contienen al menos cinco celdas o que carecen del atributo de posición son descartadas, ya que corresponden a filas auxiliares del HTML sin datos de jugadores.

Los datos de cada jugador se almacenan en un diccionario de Python con las claves Nombre, Posicion, Edad, Club y Valor, y se acumulan en una lista que al finalizar el proceso se convierte en un DataFrame de Pandas.

3.4. Limpieza y transformación de los datos

Una vez construido el DataFrame inicial, es necesario someter los datos a un proceso de limpieza para que sean manipulables de forma numérica. En el caso de la columna de edad, el valor extraído de la web incluye la fecha de nacimiento entre paréntesis junto a la edad. Mediante operaciones de cadena de texto, se aísla únicamente el valor numérico de la edad y se convierte al tipo entero.

La columna de valor de mercado presenta el dato en formato textual con el símbolo del euro y la abreviatura 'mill.' para indicar millones. Se aplican transformaciones de sustitución de texto para eliminar estos caracteres y separadores, y finalmente se convierte el valor resultante a un número decimal (tipo float). Este proceso garantiza que ambas variables puedan utilizarse en cálculos estadísticos y representaciones gráficas posteriores.

4. Desarrollo del Análisis

4.1. Análisis por posición

El primer bloque de análisis agrupa a los jugadores según su posición en el campo, estableciendo cuatro categorías: Portero, Defensa, Centrocampista y Delantero. Para cada grupo se calcula tanto el valor de mercado total como el valor medio de los jugadores que lo componen, y se imprime un listado detallado con el nombre, club, edad y valor de cada convocado.

A nivel táctica, este análisis permite identificar de forma inmediata la distribución numérica de la plantilla. La convocatoria sigue una estructura habitual en el fútbol de selecciones, con un número reducido de porteros, un bloque defensivo sólido, y una proporción destacada de centrocampistas y delanteros. Desde el punto de vista económico, las diferencias de valor medio entre líneas revelan en qué demarcaciones se concentra el mayor potencial de mercado de la selección.

Para visualizar esta distribución de forma clara, se genera un gráfico de barras en el que cada barra representa el número de jugadores convocados en cada posición, acompañado de la etiqueta numérica correspondiente. Los colores diferenciados por categoría facilitan la lectura e interpretación del gráfico.

4.2. Análisis por valor de mercado

El segundo bloque de análisis aborda la jerarquía de valor económico dentro de la plantilla. Se calcula en primer lugar el valor medio del conjunto total de convocados, que sirve como referencia para evaluar el nivel del grupo. A continuación, los jugadores se ordenan de mayor a menor valor, identificando los cinco más valiosos y los cinco con menor cotización en el mercado.

Este análisis pone de relieve la marcada asimetría existente en la distribución de valores: un grupo reducido de jugadores concentra una proporción muy elevada del valor total de la plantilla, mientras que la mayoría se sitúa en rangos intermedios o bajos. Para visualizar esta distribución se emplea un histograma con curva de densidad (KDE) superpuesta, que permite apreciar de forma intuitiva la concentración de valores y la presencia de jugadores con cotizaciones excepcionalmente altas que actúan como valores atípicos.

4.3. Relación entre edad y valor de mercado

Mediante un gráfico de dispersión (scatter plot) se analiza la relación existente entre la edad de los jugadores y su valor de mercado. Cada punto del gráfico representa a un jugador, identificado además con una etiqueta con su nombre, lo que facilita la contextualización individual de cada caso.

El análisis visual de este gráfico evidencia una tendencia característica del mercado futbolístico: los jugadores de mayor valor tienden a concentrarse en la franja de edad comprendida entre los 22 y los 28 años aproximadamente, que representa el período de mayor rendimiento y proyección. A partir de esa franja, el valor de mercado tiende a descender de forma progresiva conforme avanza la edad del jugador, aunque existen excepciones notables relacionadas con el rendimiento deportivo o el liderazgo dentro del equipo.

4.4. Distribución del valor de mercado por clubes de procedencia

Para analizar el peso económico que aportan los diferentes clubes a la selección española, se genera un gráfico de tipo donut (tarta con hueco central) en el que cada sector representa la proporción del valor de mercado total que corresponde a los jugadores de cada equipo. En el centro del gráfico se muestra el valor total acumulado de toda la plantilla, expresado en millones de euros.

Este tipo de visualización permite identificar de un vistazo qué clubes acumulan mayor representación económica en la convocatoria. En la selección española es

habitual que los grandes clubes de La Liga —especialmente el Real Madrid y el FC Barcelona— concentren una parte muy significativa del valor total, aunque también aparecen clubes extranjeros de primer nivel cuyas cifras reflejan el carácter internacional del fútbol de élite actual.

4.5. Mapa de calor: concentración de valor por posición y club

Se elabora un mapa de calor (heatmap) que cruza las variables posición en el campo y club de procedencia, mostrando para cada combinación el valor de mercado acumulado. La intensidad de color de cada celda refleja la magnitud del valor económico correspondiente: los tonos más oscuros indican las combinaciones con mayor concentración de valor.

Este gráfico es especialmente útil para detectar qué clubes aportan mayor valor en cada línea del campo, y si existe una dependencia táctica y económica de la selección respecto a determinados equipos en posiciones estratégicas. La escala de color continua empleada permite comparar de forma precisa las diferencias entre combinaciones.

4.6. Mapa de influencia de los clubes (grafo de red)

La última visualización del análisis adopta la forma de un grafo de red. En el centro del grafo se sitúa el nodo principal, que representa a la selección española. En torno a él se disponen los nodos correspondientes a cada club de procedencia, cuya proximidad al centro y tamaño del nodo son proporcionales al número de jugadores que aportan a la convocatoria. Las aristas que conectan cada club con el nodo central tienen un grosor proporcional al mismo criterio, reforzando visualmente la jerarquía de influencia.

Este tipo de representación permite comprender de forma intuitiva qué clubes tienen mayor peso en la configuración de la plantilla convocada. Los clubes con mayor aportación aparecen como nodos de mayor tamaño más próximos al centro, mientras que los que aportan un único jugador quedan ubicados en la periferia de la red.

5. Exportación de Datos

Una vez finalizado el proceso de scraping, limpieza y análisis, el dataset resultante se exporta a dos formatos estándar: CSV y JSON. La exportación en formato CSV genera un archivo tabular con una fila por jugador y una columna

por variable, lo que facilita su apertura y manipulación en herramientas como Excel, LibreOffice Calc o cualquier entorno de análisis de datos. La exportación en formato JSON organiza los mismos datos como una lista de registros, donde cada jugador queda representado como un objeto con sus atributos clave-valor, con una indentación de cuatro espacios para mejorar la legibilidad.

La elección de estos dos formatos complementarios responde a su amplia compatibilidad con las principales librerías de análisis de datos en Python y con herramientas externas de visualización e integración. El formato CSV es especialmente adecuado para análisis tabulares posteriores, mientras que JSON resulta idóneo para su consumo desde aplicaciones web o su integración en pipelines de datos más complejos. Ambos formatos son de carácter abierto e interoperable, lo que garantiza la reutilización del dataset por cualquier miembro del equipo sin necesidad de conversiones adicionales.

6. Conclusiones

Este proyecto nos ha permitido llevar a cabo de forma satisfactoria el ciclo completo de un proyecto de text mining y web scraping: desde la identificación de una fuente de datos web estructurada y su extracción automatizada, hasta la limpieza, análisis y visualización de la información obtenida.

Desde el punto de vista técnico, el uso combinado de las librerías Requests y BeautifulSoup ha resultado eficaz para acceder y parsear el contenido HTML de Transfermarkt, mientras que Pandas ha simplificado considerablemente las tareas de limpieza y transformación de los datos. Las librerías de visualización — Matplotlib, Seaborn y NetworkX— han permitido generar representaciones gráficas de distinta naturaleza, adaptadas a los diferentes tipos de análisis realizados.

En cuanto a los resultados del análisis, los datos de la convocatoria española reflejan una plantilla de alto nivel económico, con una marcada concentración del valor de mercado en un grupo reducido de jugadores jóvenes procedentes de los principales clubes europeos. La distribución posicional es coherente con los sistemas tácticos habituales en el fútbol de selecciones, con un equilibrio razonable entre las distintas demarcaciones. El análisis de la relación entre edad y valor de mercado confirma la tendencia generalizada en el fútbol de élite: el

pico de valor coincide con la franja de madurez deportiva, situada entre los 22 y los 28 años aproximadamente.

A nivel de clubes de procedencia, queda patente el peso histórico y económico de los grandes equipos de La Liga española en la configuración de la selección nacional, aunque la presencia de jugadores de clubes extranjeros evidencia también la proyección internacional del fútbol español en las últimas décadas.